Finite Markov Decision Processes

Richard S. Sutton and Andrew G. Barto, Reinforcement Learning: An Introduction (2nd Edition) Chapter3

유희철

2026-03-28

목차

1. Recap - Chap1
2. Who with Whom?
3. For What?
4. How to measure?
5. How to represent
6. How to solve?
7. The End?

Recap - Chap.1

강화학습 넌 어디서 나타났냐

Recap - Chap.1

강화학습 넌 어디서 나타났냐
갑자기 쏟아지는 Terminology

Reward?

Action?

State?

Value?

Environment?

Policy?

Return?

Episode?

Agent?

Recap - Chap.1

Trial and Error Learning

Optimal Control Theory

Recap - Chap.1

Bellman and Dreyfus, *Applied Dynamic Programming* (1962)

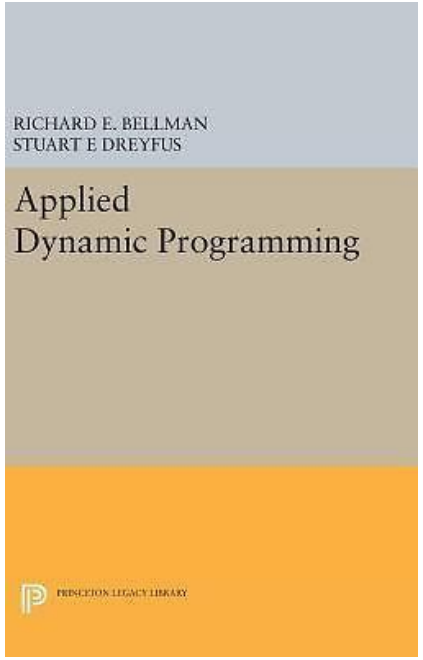

Optimal Control(DP/MDP)의 문제점 : Dynamics가 있어야 해

그럼.. Dynamics를 모르는 환경에서는 이 문제를 못푸네?

(DP를 통해 문제를 푸려면 모든 환경이 알려져 있어야 해)

(Bellman도 MDP는 모두 알려져 있다고 가정하고 알고리즘을 계산했네)

MDP와 Control 문제는.. 학습과는 거리가 있어 보이는데?

모델이 없어도 일단 시행을 하자! MDP 환경이라고 가정하고 이 환경을 경험하게 하자

시행착오를 하고 여기서 얻은 결과로 Bellman Equation을 점진적으로 맞춰가자

Reference: 1) https://www.cs.rhul.ac.uk/~chrisw/RL_some_history.html, 2) https://oecs.mit.edu/pub/k2ek981x/release/2
3) Dimitri P. Bertsekas, *Ten Key Ideas for Reinforcement Learning and Optimal Control*, MIT(2019)

Recap - Chap.1

Bellman and Dreyfus, *Applied Dynamic Programming* (1962)

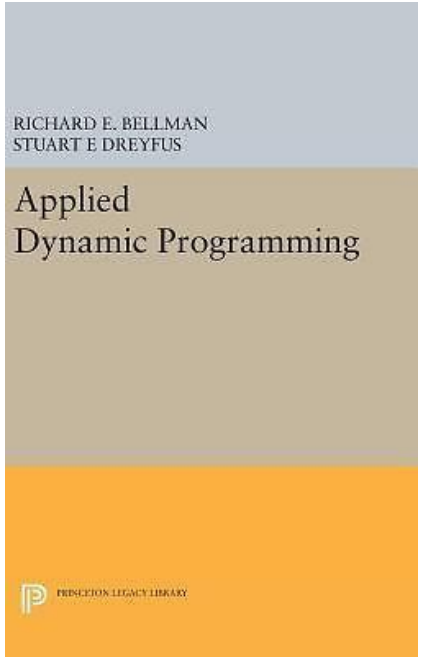

Optimal Control(DP/MDP)의 문제점 : Dynamics가 있어야 해

그럼.. Dynamics를 모르는 환경에서는 이 문제를 못푸네?

(DP를 통해 문제를 푸려면 모든 환경이 알려져 있어야 해)

(Bellman도 MDP는 모두 알려져 있다고 가정하고 알고리즘을 계산했네)

MDP와 Control 문제는.. 학습과는 거리가 있어 보이는데?

푸는 방법은 알고 있으니 (Optimal Control, DP, MDP)

시행착오만 하면 돼 (Trial and Error Learning)

Reference: 1) https://www.cs.rhul.ac.uk/~chrisw/RL_some_history.html, 2) https://oecs.mit.edu/pub/k2ek981x/release/2
3) Dimitri P. Bertsekas, *Ten Key Ideas for Reinforcement Learning and Optimal Control*, MIT(2019)

Recap - Chap.1

"Learning from Interaction"

근데 제어에 학습을 접목시킬 수가 있나?

제어는? Offline Backward Computation

학습은? Forward Adaptation

DP Algorithm: Formal Statement

Go backward to compute the optimal costs $J_k^*(x_k)$ of the x_k-tail subproblems

Start with

$$J_N^*(x_N) = g_N(x_N), \qquad \text{for all } x_N,$$

and for $k = 0, \ldots, N-1$, let

$$J_k^*(x_k) = \min_{u_k \in U_k(x_k)} \left[g_k(x_k, u_k) + J_{k+1}^*(f_k(x_k, u_k)) \right], \qquad \text{for all } x_k.$$

The optimal cost $J^*(x_0)$ is obtained at the last step: $J_0^*(x_0) = J^*(x_0)$.

그럼 제어 문제는.. 학습으로 못 푸는거 아니야?

Temporal-Difference Learning

Reference: 1) https://www.cs.rhul.ac.uk/~chrisw/RL_some_history.html, 2) https://oecs.mit.edu/pub/k2ek981x/release/2
3) Dimitri P. Bertsekas, *Ten Key Ideas for Reinforcement Learning and Optimal Control*, MIT(2019)

Recap - Chap.1

Barto, Sutton and Watkins, *Learning and Sequential Decision Making* (1989)

TD Learning만 있었던건 아니다

Q-Learning / Actor-Critic 등등…

근데 이들은 TD의 방법론을 내포하고 있음

특히 동물 행동학에서도 TD-learning 기반 알고리즘으로 잘 설명되는 방식의 보상 예측 오차 신호가 도파민의 보상 신호와 비슷하다~라는 컨센서스

Learning and Sequential Decision Making†

Andrew G. Barto
Department of Computer and Information Science
University of Massachusetts, Amherst MA 01003

R. S. Sutton
GTE Laboratories Incorporated
Waltham, MA 02254

C. J. C. H. Watkins
Philips Research Laboratories
Cross Oak Lane, Redhill Surrey RH1 5HA, England

COINS Technical Report 89-95
September 1989

Abstract—In this report we show how the class of adaptive prediction methods that Sutton called "temporal difference," or TD, methods are related to the theory of sequential decision making. TD methods have been used as "adaptive critics" in connectionist learning systems, and have been proposed as models of animal learning in classical conditioning experiments. Here we relate TD methods to decision tasks formulated in terms of a stochastic dynamical system whose behavior unfolds over time under the influence of a decision maker's actions. Strategies are sought for selecting actions so as to maximize a measure of long-term payoff gain. Mathematically, tasks such as this can be formulated as Markovian decision problems, and numerous methods have been proposed for learning how to solve such problems. We show how a TD method can be understood as a novel synthesis of concepts from the theory of stochastic dynamic programming, which comprises the standard method for solving such tasks when a model of the dynamical system is available, and the theory of parameter estimation, which provides the appropriate context for studying learning rules in the form of equations for updating associative strengths in behavioral models, or connection weights in connectionist networks. Because this report is oriented primarily toward the non-engineer interested in animal learning, it presents tutorials on stochastic sequential decision tasks, stochastic dynamic programming, and parameter estimation.

Reference: 1) https://www.cs.rhul.ac.uk/~chrisw/RL_some_history.html, 2) https://oecs.mit.edu/pub/k2ek981x/release/2
3) Dimitri P. Bertsekas, *Ten Key Ideas for Reinforcement Learning and Optimal Control*, MIT(2019)

Recap - Chap.1

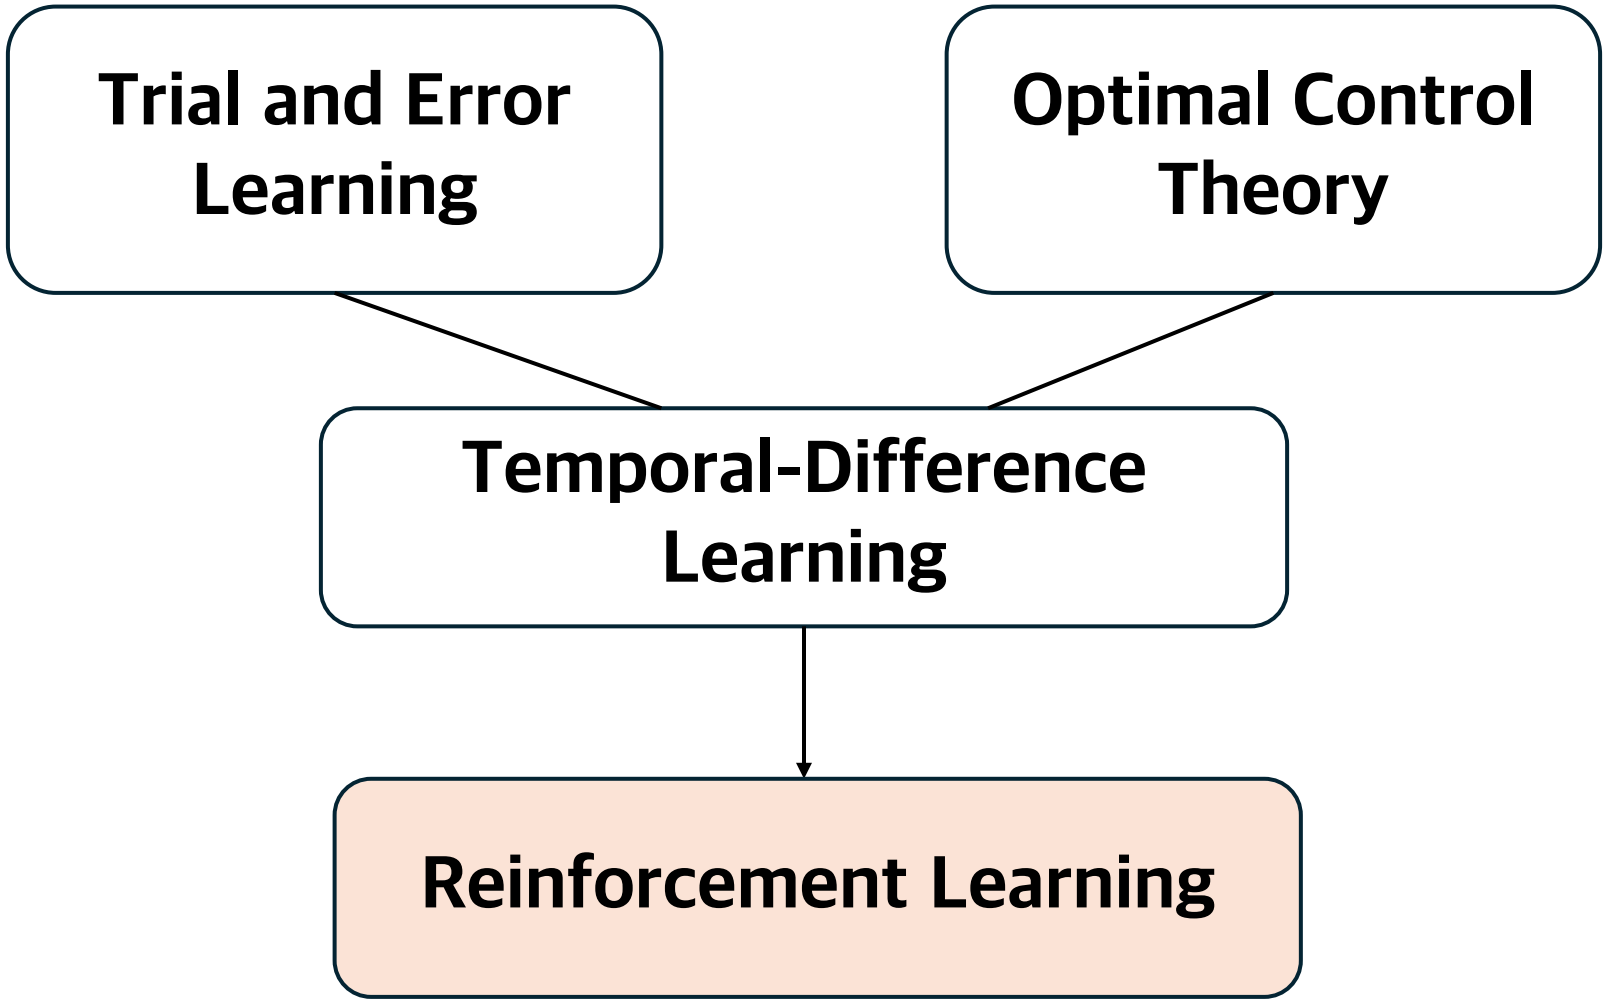
Trial and Error Learning
Optimal Control Theory
Temporal-Difference Learning
Reinforcement Learning

Recap - Chap.1

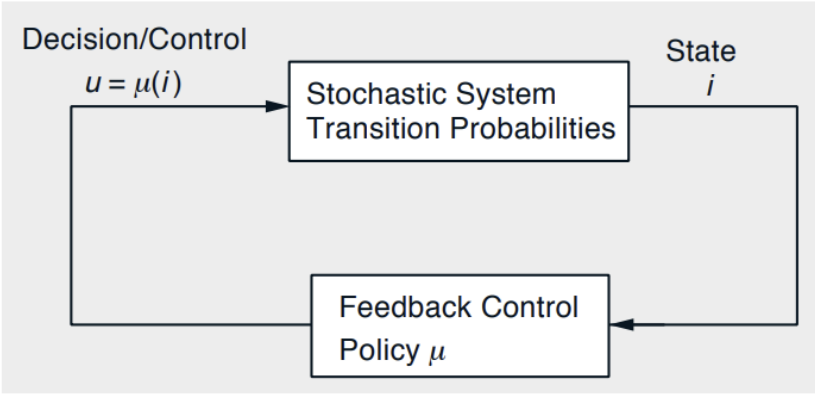

Figure 1.1: Structure of a discrete-time dynamic system under feedback control.

Dimitri P. Bertsekas and John N. Tsitsiklis, *Neuro-Dynamic-Programming* (1996)

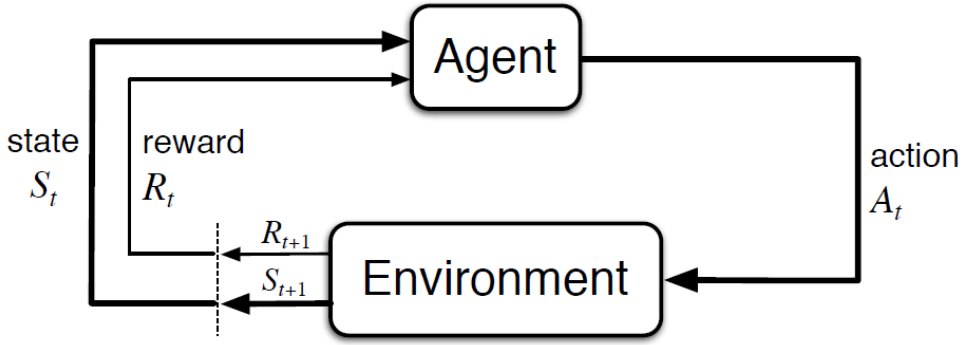

Figure 3.1: The agent–environment interaction in a Markov decision process.

Recap - Chap.1

강화학습은

Trial and error라는 학습 철학 위에서

Optimal Control과 DP가 제공한 최적화 구조를 바탕으로

Temporal Difference Learning 같은 샘플 기반 업데이트를 통해

환경을 모르는 상황에서도 경험으로 가치나 정책을 근사하여 더 나은 의사결정을 학습하는 방식이다.

Recap - Chap.1

강화학습은

보상 최대화

장기적 의사결정 문제

RL 특장점?

Trial and error라는 학습 철학 위에서

Optimal Control과 DP가 제공한 최적화 구조를 바탕으로

Temporal Difference Learning 같은 샘플 기반 업데이트를 통해

환경을 모르는 상황에서도 경험으로 가치나 정책을 근사하여 더 나은 의사결정을 학습하는 방식이다.

Recap - Chap.1

강화학습은

보상 최대화

장기적 의사결정 문제

RL 특장점?

Trial and error라는 학습 철학 위에서

Optimal Control과 DP가 제공한 최적화 구조를 바탕으로

Temporal Difference Learning 같은 샘플 기반 업데이트를 통해

환경을 모르는 상황에서도 경험으로 가치나 정책을 근사하여 더 나은 의사결정을 학습하는 방식이다.

→ Temporal Difference Learning 에 편향된 설명

Recap - Chap.1

강화학습은

Trial and error라는 학습 철학 위에서

Optimal Control과 DP가 제공한 최적화 구조를 바탕으로

시행 착오를 통한 학습과 장기 누적 보상 최적화를 결합해서

모델을 모르더라도 경험으로 더 좋은 정책을 학습하는 방식이다.

Recap - Chap.1

이제야 합의를 볼 수 있다

Reward?

Action?

State?

Value?

Environment?

Policy?

Return?

Episode?

Agent?

Who with Whom?

The Agent-Environment Interface

Bandit에서는 Stationary State를 가정했었다.

$$q_*(a) = \mathbb{E}[R_t | A_t = a]$$

시간에 따라 각 행동의 보상 분포가 변하지 않는다 + 의사 결정을 나타내는 State Transition이 없다

→ 지금 어떤 상태인지 내 다음 행동이 다음 상태를 어떻게 바꿀지는 하나도 중요하지 않고 실제로 바뀌지도 않음

RL 에서는? 그런 가정은 없음

$$q_*(s, a), v_*(s)$$

지금 상태를 고려해서 보상을 계산해야 함

현재 상태에서의 어떤 행동이 다음 상태에 영향을 준다 → 현재 상태에서의 어떤 행동이 미래의 보상을 바꾼다

Who with Whom?

The Agent-Environment Interface

Assumption : MDP(Markov Decision Process)

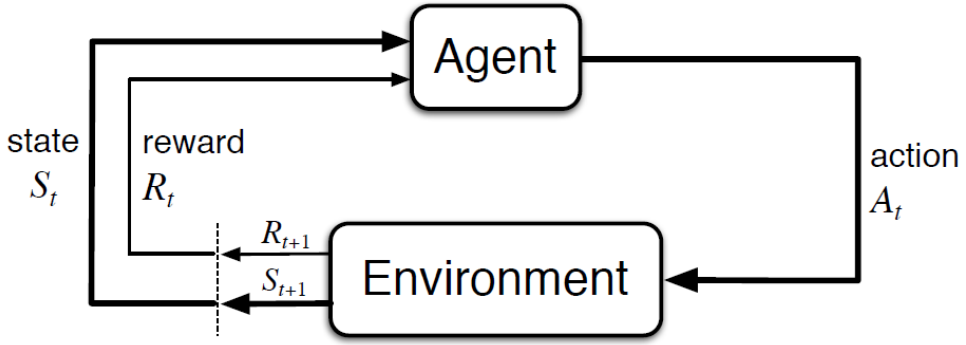

Figure 3.1: The agent–environment interaction in a Markov decision process.

$$R_{t+1}, S_t, A_t, R_t, S_{t-1}, A_{t-1}, R_{t-1}, \dots S_1, A_1, R_1, S_0, A_0$$

$$P(S_{t+1}, R_{t+1} | S_t, A_t, S_{t-1}, A_{t-1}, \dots, S_0, A_0) = \boldsymbol{P(S_{t+1}, R_{t+1} | S_t, A_t)}$$

$$\boldsymbol{p(s', r | s, a)}$$

Who with Whom?

The Agent-Environment Interface

Assumption : MDP(Markov Decision Process)

State는 이전의 모든 Agent-Environment interaction에 대한 정보를 내포하고 있다.

→ Markov Property

$$p(s', r|s, a)$$

$$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r|s, a) = 1$$

As in all of artificial intelligence, there is a tension between breadth of applicability and mathematical tractability.

Chap 17에서는 non-Markov Observation을 Markov State로 만드는 방법을 다룸

Who with Whom?

The Agent-Environment Interface

Assumption : MDP(Markov Decision Process)

$$p(s', r|s, a)$$

- **State-Transition Probabilities**

$$p(s'|s, a) = \sum_{r \in \mathcal{R}} p(s', r|s, a)$$

- **Expected Rewards for state-action pairs**

$$r(s, a) = \mathbb{E}[R_t|S_{t-1} = s, A_{t-1} = a] = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r|s, a)$$

- **Expected Rewards for state-action-next-state triples**

$$r(s, a, s') = \mathbb{E}[R_t|S_{t-1} = s, A_{t-1} = a, S_t = s'] = \sum_{r \in \mathcal{R}} r \frac{p(s', r|s, a)}{p(s'|s, a)}$$

Who with Whom?

The Agent-Environment Interface

Assumption : MDP(Markov Decision Process)

General Rule:

- 에이전트(Agent)가 바꿀 수 없는 모든 것은 환경(Environment)로 취급한다
- 그렇다고 환경의 모든 정보를 에이전트가 모른다고 생각하지는 않는다

<u>에이전트와 환경의 경계는 에이전트가 무엇을 아는가가 아니라 무엇을 임의로 통제할 수 없는가에 의해 정해진다</u>

이 경계는 우리가 어떻게 목적을 설계하는지에 따라 달라질 수 있다

→ 어떤 Decision Making Task를 정의하느냐에 따라 달라진다

→ 어떤 State, Action, Reward를 정하는지에 따라 달라진다

MDP는 문제를 이 3가지 신호로 축약한 추상화다.

Who with Whom?

The Agent-Environment Interface

s	a	s'	$p(s' \mid s, a)$	$r(s, a, s')$
high	search	high	α	$r_{\texttt{search}}$
high	search	low	$1-\alpha$	$r_{\texttt{search}}$
low	search	high	$1-\beta$	-3
low	search	low	β	$r_{\texttt{search}}$
high	wait	high	1	$r_{\texttt{wait}}$
high	wait	low	0	-
low	wait	high	0	-
low	wait	low	1	$r_{\texttt{wait}}$
low	recharge	high	1	0
low	recharge	low	0	-

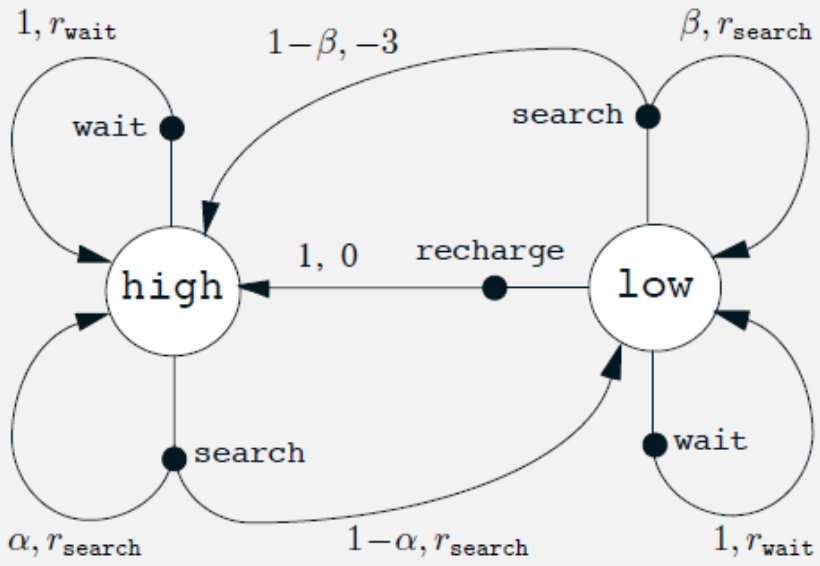

For What?

Goals and Rewards

Goal은 Reward로 정의된다 → **Agent의 목적은 시간에 걸친 누적 Reward의 기대값을 최대화 하는 것이다.**

시간 t에 받는 Reward : R_t

Reward Hypothesis:

목표와 목적(Goal)은 Reward라는 스칼라 값 누적합의 기대값을 최대화하는 것이다.

즉각적 보상만을 키우는 것이 아님.

장기 누적 보상을 키우는 것이 중요함 → 장기적으로 원하는 행동을 유도하는 목적 함수

설계할 땐 "어떻게"가 중요한 게 아니라 "무엇을"이 중요

→ 어떻게에 너무 집착하면 Subgoal만 달성하는 사례가 발생할 수도 있음

How to measure?

Returns and Episodes

Goal은 Reward로 정의된다 → Agent의 목적은 시간에 걸친 누적 Reward의 기대값을 최대화 하는 것이다.

시간 t에 한 행동으로 받는 Reward : R_{t+1}

시간에 걸친 **누적 Reward**: $R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T$

이를 이제 Return 보상 (G_t)이라 하자

$$\boldsymbol{G_t = R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T}$$

근데 모든 문제에 대해 이런 Return을 사용하는게 합리적일까?

예컨대 끝이 없는 문제라면?

How to measure?

Returns and Episodes

Episodic Task

$$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T$$

종료 시점이 있는 경우 (Terminal State가 존재하는 경우): 원래의 Return 공식을 사용해도 문제 X

→ **이 한 사이클을 Episode라고 부른다.**

종료 시간 T는 Episode마다 달라질 수 있다

Continuing Task

Terminal State가 없는 경우 계속 돌아가는 공정 제어 같은 예시는 멈춰서는 안된다 $(T \to \infty)$

그럼 Return이 무한대가 될 수도 있네? 그럼 문제가 발생

→ **Discounting Factor γ 를 도입하자**

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots$$

How to measure?

Returns and Episodes

Continuing Task

Terminal State가 없는 경우 ($T \to \infty$) Return이 무한대가 될 수도 있음

→ Discounting Factor γ 를 도입하자

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

- Return을 Finite하게 만드는 효과 ($0 \le \gamma < 1$)
- 미래 보상을 현재보다 덜 중요하게 본다
  - k step 뒤의 reward는 γ^k 만큼 줄어든 가치로 취급
- γ값을 조정해서 Agent를 근시안적으로 만들지 원시안적으로 만들지 설계할 수 있다

Return 식은 재귀식

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = R_{t+1} + \gamma G_{t+1}$$

How to measure?

Returns and Episodes

Pole-Balancing Problem: 문제를 설계하는 것은 설계자 마음

Episodic :

실패 전까지 매 Step 보상을 +1

- K step에서 실패하면 보상은 K
- Return을 Maximize 하는 것은 K를 Maximize 하는 것

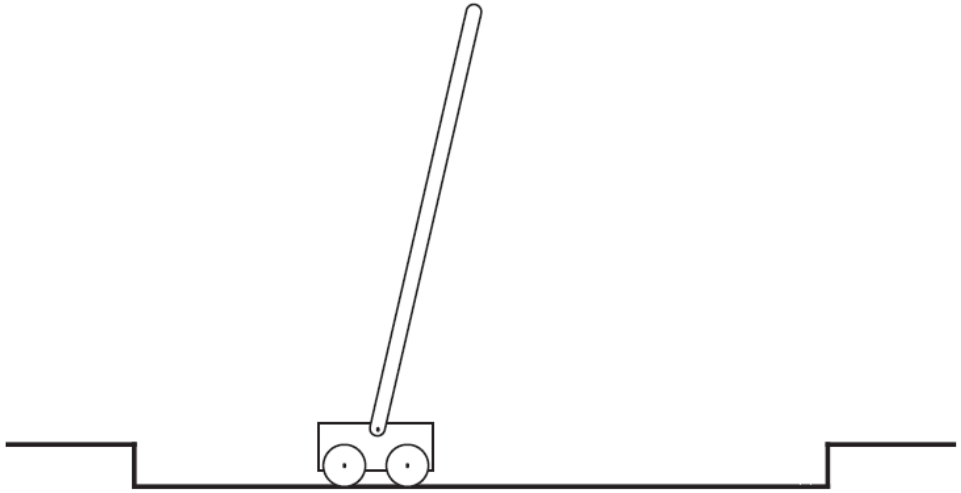

Continuing :

실패할 때만 보상을 -1, 나머지 시행에서는 보상을 0

- K step에서 실패하면 보상은 $-\gamma^K$
- Return을 Maximize 하는 것은 K를 Maximize 하는 것
    - K가 커져야 $-\gamma^K$가 작아지면서 Maximize 됨

How to measure?

Unified Notation for Episodic and Continuing Tasks

Episodic Task와 Continuing Task의 개념을 하나로 합치자!

그래야 나중에 Bellman Equation과 Value function을 두 개씩 정의하지 않아도 되니까

Terminal State를 Absorbing State로 생각한다

이 State에 진입하면 계속 자기 자신으로 회귀. Reward는 0만 나옴.

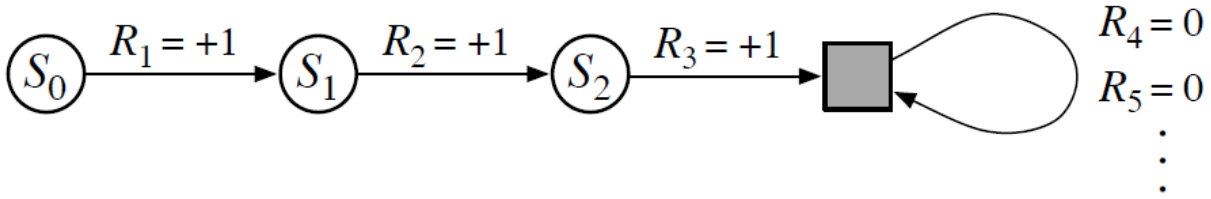

$$G_t = \sum_{k=t+1}^{\infty} \gamma^{k-t-1} R_k$$

How to represent

Policies and Value Functions

Policy

각 State에서 Action을 선택할 확률을 주는 함수

$$\pi(a|s)$$

$$\mathbb{E}[R_{t+1}|S_t = s] = \sum_a \pi(a|S_t) \sum_{s',r} rp(s',r|s,a)$$

- 강화학습은 Value Function을 추정함
- 에이전트가 주어진 상태에 있는 것이 “얼마나 좋은지”를 추정하는 것인데
- “얼마나 좋은지”는 미래에 대한 기대 보상으로 정의됨 그리고 이 보상은 에이전트의 행동에 따라 달라짐

→ **이 행동 방식은 “Policy” 정책에 의존하고 따라서 Value function은 정책에 따라 정의가 된다.**

How to represent

Policies and Value Functions

Value Function

Policy π 일 때 State s의 Value Function은 다음과 같이 **정의**된다.

$$v_\pi(s) = \mathbb{E}[G_t | S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,|S_t = s\right]$$

- v_π 를 State-Value Function 이라고도 한다

Policy π 일 때 State s에서 Action a의 Value Function은 다음과 같이 **정의**된다.

$$q_\pi(s, a) = \mathbb{E}[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,|S_t = s, A_t = a\right]$$

- q_π를 Action-Value Function 이라고도 한다

How to represent

Policies and Value Functions

Value Function

Policy $\boldsymbol{\pi}$ 일 때 State s의 Value Function은 다음과 같이 **정의**된다.

$$\boldsymbol{v_\pi(s)} = \mathbb{E}[\boldsymbol{G_t}|\boldsymbol{S_t} = \boldsymbol{s}] = \mathbb{E}_{\boldsymbol{\pi}}\left[\sum_{\boldsymbol{k=0}}^{\infty} \boldsymbol{\gamma^k R_{t+k+1}} \,|\boldsymbol{S_t} = \boldsymbol{s}\right]$$

- 상태 s에서 시작해서 Policy $\boldsymbol{\pi}$ 를 따라가면 얻을 것이라고 기대되는 Return 값

How to represent

Policies and Value Functions

Value Function

Policy π 일 때 State s에서 Action a의 Value Function은 다음과 같이 **정의**된다.

$$q_\pi(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,|S_t = s, A_t = a\right]$$

- 상태 s에서 행동 a를 취하고 Policy π 를 따라가면 얻을 것이라고 기대되는 Return 값

How to represent

Policies and Value Functions

Value Function

가치 함수는 시행착오로 추정한다.

$$\boldsymbol{v_\pi(s) = \mathbb{E}[G_t | S_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,| S_t = s \right]}$$

$$\boldsymbol{q_\pi(s,a) = \mathbb{E}[G_t | S_t = s, A_t = a] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,| S_t = s, A_t = a \right]}$$

우리는 이 수식에서 모르는 것이 너무 많다. (정책 함수, 상태 전이 확률, Reward의 분포, 궤적의 종류..)

- 직접 시행을 겪으면서 Return을 관측하고 Return을 샘플링해서 Value를 Estimate 함
- Monte Carlo / 큰 수의 법칙
- 결국 진짜 $\boldsymbol{v_\pi(s)}$, $\boldsymbol{q_\pi(s,a)}$로 수렴하게 될 것임

How to represent

Policies and Value Functions

	상태/행동 공간 크기가 작다	상태/행동 공간 크기가 크다
모델을 알고 있다	**Dynamic Programming**	**Approximation Method**
모델을 모른다	**Monte Carlo, TD SARSA, Q-Learning**	**DQN, Actor-Critic, PPO**

How to represent

Policies and Value Functions

	상태/행동 공간 크기가 작다	상태/행동 공간 크기가 크다
모델을 알고 있다	**Dynamic Programming**	**Approximation Method**
모델을 모른다	**Monte Carlo, TD SARSA, Q-Learning**	**DQN, Actor-Critic, PPO**

신경망으로 접근하기도 함

How to represent

Policies and Value Functions

Value Function

각 가치 함수는 재귀적으로 표현할 수 있다

$$v_\pi(s) = \mathbb{E}[G_t|S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,|S_t = s\right]$$

$$\begin{aligned} v_\pi(s) &= \mathbb{E}[G_t|S_t = s] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1}|S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)\left[r + \gamma \mathbb{E}[G_{t+1}|S_{t+1} = s']\right] \\ &= \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)\left[r + \gamma v_\pi(s')\right] \end{aligned}$$

이 식을 Bellman Equation for v_π라고 한다.

How to represent

Policies and Value Functions

Value Function

$$v_\pi(s) = \sum_a \pi(a|s)\, q_\pi(s,a)$$

$$q_\pi(s,a) = \sum_{s',r} p(s',r|s,a)\,[r + \gamma v_\pi(s)]$$

q_π에 대해서도 재귀적으로 작성할 수 있다

$$q_\pi(s,a) = \mathbb{E}[G_t|S_t = s, A_t = a] = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1}|S_t = s, A_t = a]$$
$$= \sum_{s',r} p(s',r|s,a)\,[r + \gamma \sum_{a'} \pi(a'|s')\, q_\pi(s',a')]$$

이 식을 Bellman Equation for q_π라고 한다.

How to represent

Policies and Value Functions

Backup Diagram

Bellman Equation의 시각화 - 다음 State, Action의 Value 정보를 현재 State / State-Action 으로 가져와서 계산

- 흰색 원 : state
- 검은색 원 : state-action pair

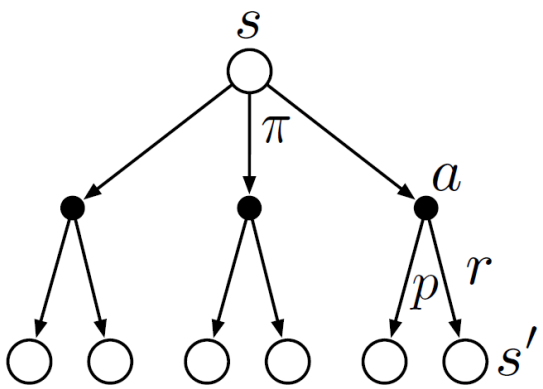

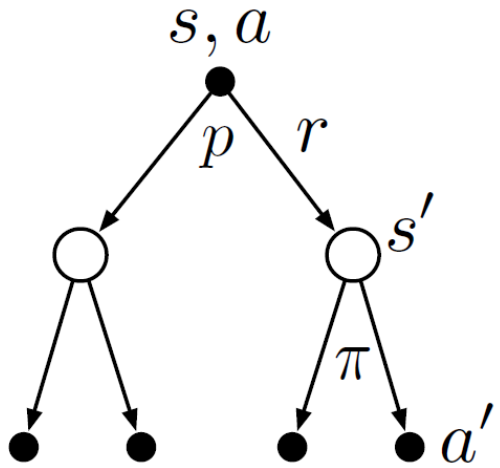

q_π backup diagram

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)\,[r + \gamma v_\pi(s')]$$

$$q_\pi(s,a) = \sum_{s',r} p(s',r|s,a)\,[r + \gamma \sum_{a'} \pi(a'|s')\, q_\pi(s',a')]$$

How to represent

Policies and Value Functions

Backup Diagram

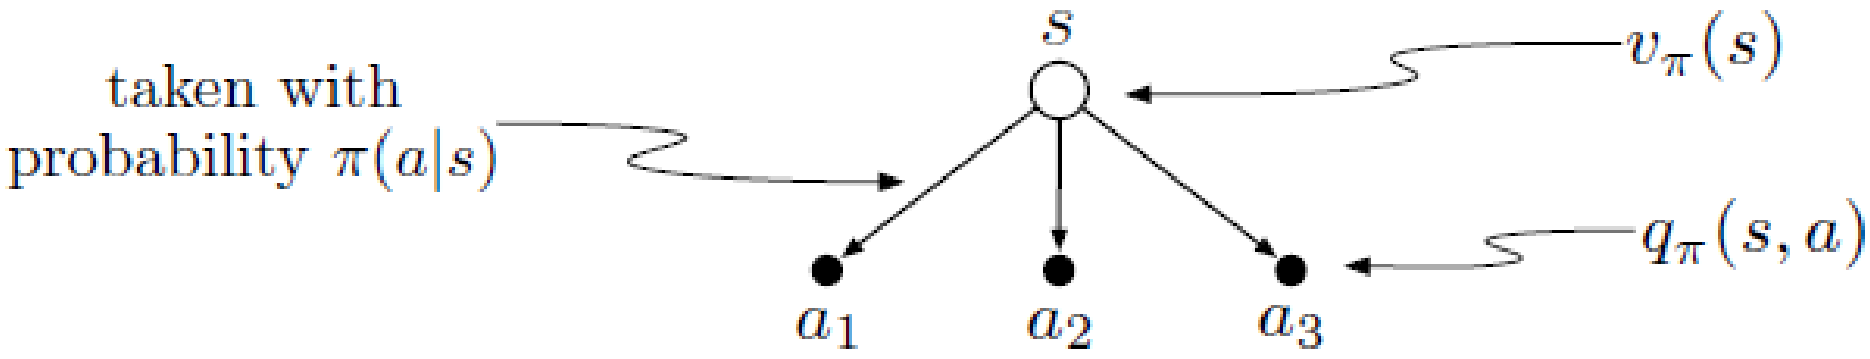

How to represent

Policies and Value Functions

Backup Diagram

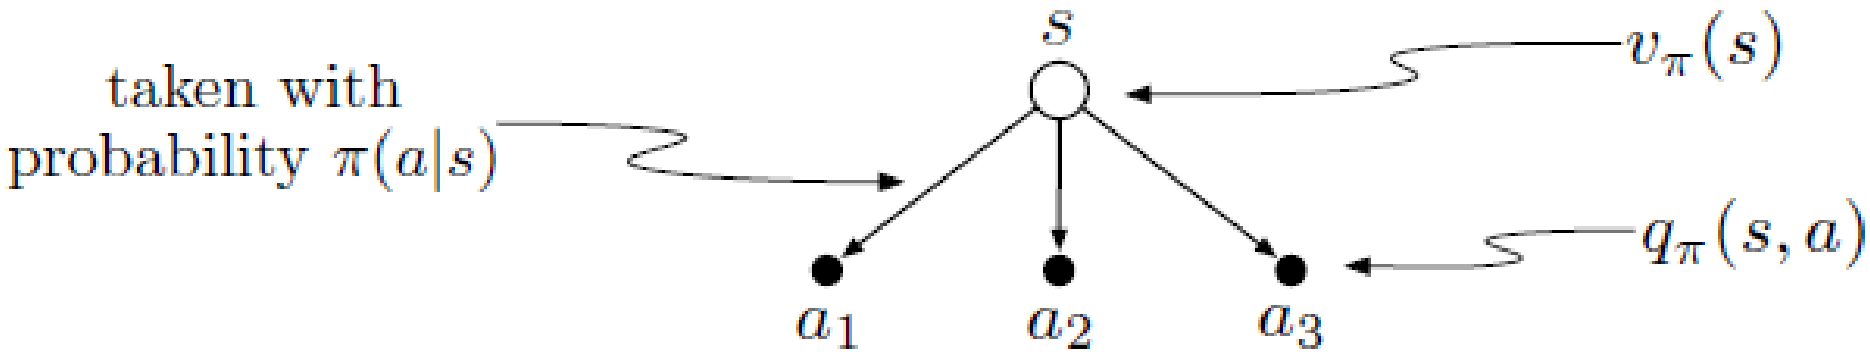

$$v_\pi(s) = \sum_a \pi(a|s)\, q_\pi(s,a)$$

How to represent

Policies and Value Functions

Backup Diagram

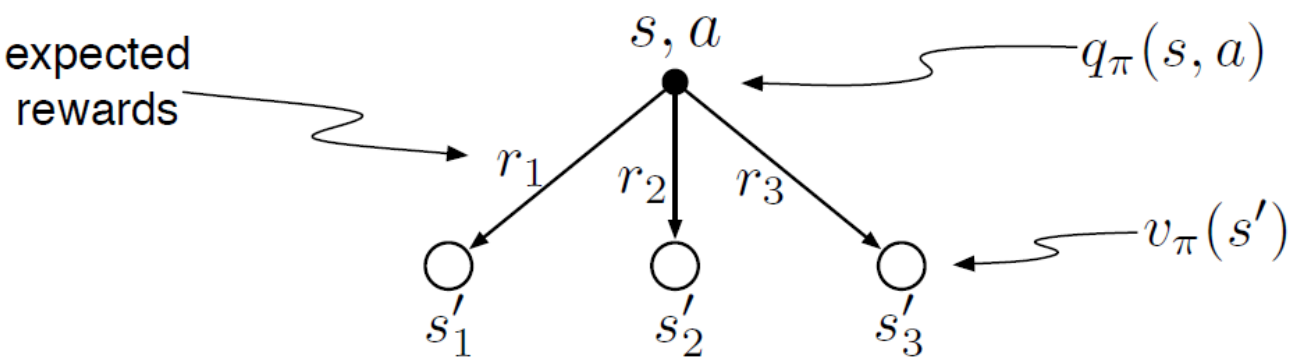

How to represent

Policies and Value Functions

Backup Diagram

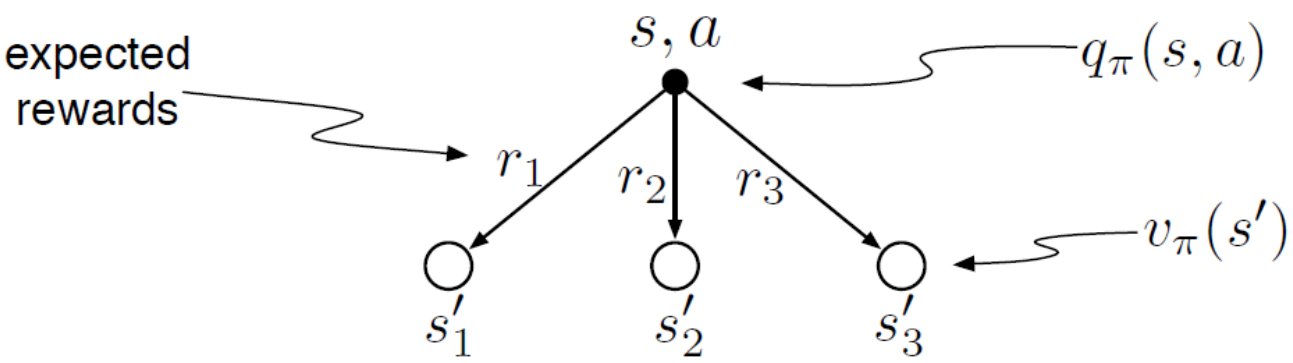

$$q_\pi(s, a) = \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_\pi(s') \right]$$

How to represent

Policies and Value Functions

Example 3.5 Grid - State Value는 어떻게 형성되는가

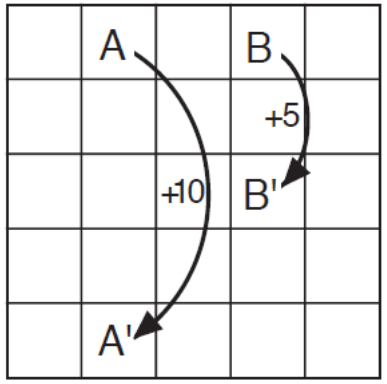

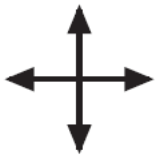

Actions

3.3	8.8	4.4	5.3	1.5
1.5	3.0	2.3	1.9	0.5
0.1	0.7	0.7	0.4	-0.4
-1.0	-0.4	-0.4	-0.6	-1.2
-1.9	-1.3	-1.2	-1.4	-2.0

- Action: 상,하,좌,우
- Reward:
  - 그리드 → 그리드 : 0
  - A → A’ : 10
  - B → B’ : 5
  - Off the Grid : -1

How to represent

Policies and Value Functions

Example 3.5 Grid

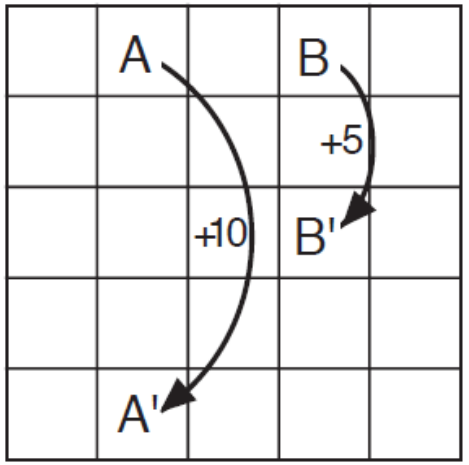

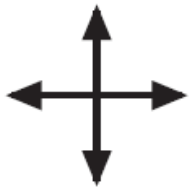

Actions

3.3	8.8	4.4	5.3	1.5
1.5	3.0	2.3	1.9	0.5
0.1	0.7	0.7	0.4	-0.4
-1.0	-0.4	-0.4	-0.6	-1.2
-1.9	-1.3	-1.2	-1.4	-2.0

$$v_{center} = \frac{0.9 \times (2.3 + 0.7 - 0.4 + 0.4)}{4} = 0.675 \sim 0.7$$

How to represent

Policies and Value Functions

Example 3.6 Golf

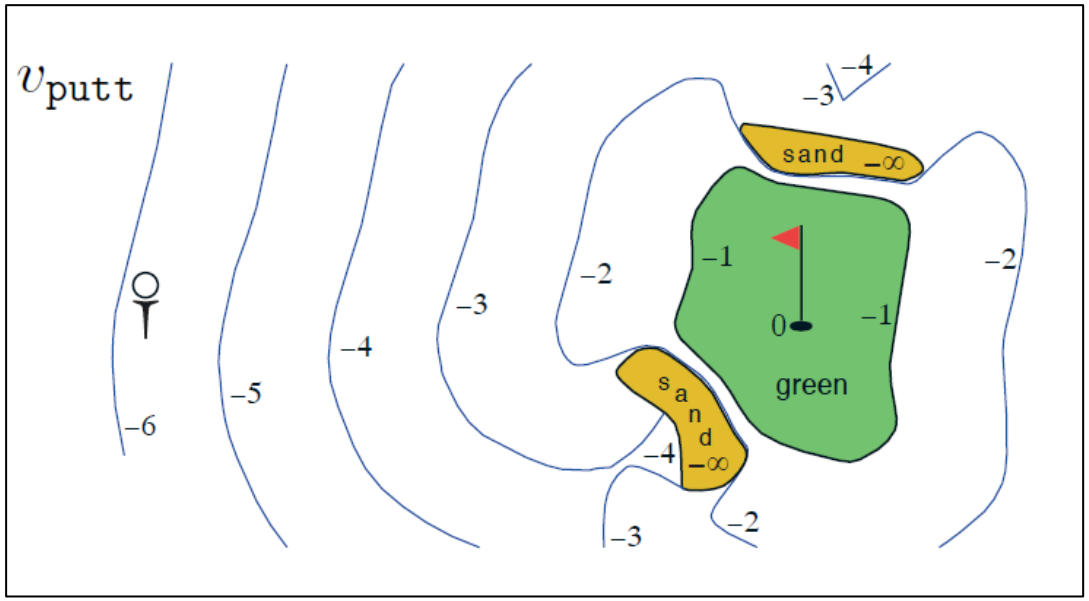

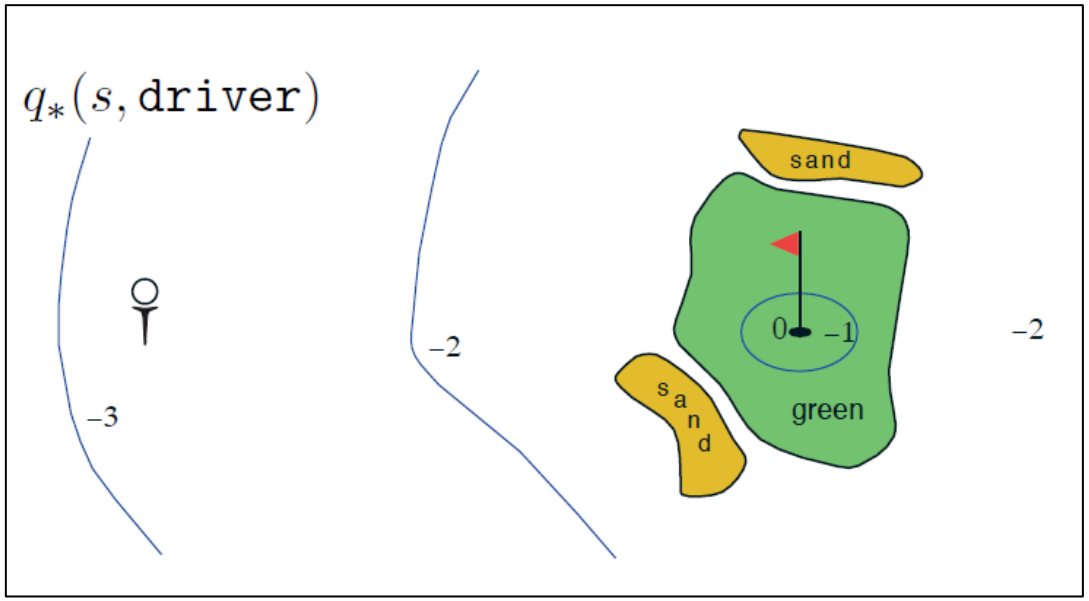

How to solve

Optimal Policies and Optimal Value Functions

모든 것이 정의되었음 : Agent, Environment, State, Action, Reward, Return, Policy, Value Function

이제 강화학습 문제를 풀 일만 남았음

근데 강화학습 문제를 푼다는 건 어떤 의미일까?

→ **장기적으로 최고의 Return을 내게 만드는 Action을 할 수 있는 Policy를 찾는 것이 강화학습 문제를 푸는 것**

→ **제일 좋은 정책이 무엇인가?**

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

여러 Policy 중에 모든 state에서 value가 가장 큰 policy를 optimal policy라 한다. 그리고 이를 $\boldsymbol{\pi_*}$ 라고 하자

$$\boldsymbol{\pi \geq \pi' \ \leftrightarrow \ v_\pi(s) \geq v_{\pi'}(s)}$$

$$\boldsymbol{v_*(s) = max_\pi v_\pi(s)}$$

$$\boldsymbol{q_*(s,a) = max_\pi q_\pi(s,a)}$$

이 때 $\boldsymbol{v_*(s)}$를 **optimal state-value function**, $\boldsymbol{q_*(s,a)}$를 **Optimal action-value function** 이라고 한다.

- $\boldsymbol{v_*(s)}$: 상태 s에서 시작했을 때 달성 가능한 최대 Expected Return
- $\boldsymbol{q_*(s,a)}$: 상태 s에서 행동 a를 취했을 때 이후에 달성 가능한 최대 Expected Return

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

특징

1. Optimal Policy는 Unique하지 않다
2. Optimal Policy는 모두 같은 optimal state-value function, optimal action-value function을 공유한다
3. Any MDP에 대해서 Optimal Policy는 Deterministic하다.

$$\boldsymbol{\pi_1 \neq \pi_2 \ \longrightarrow \ v_{\pi_1 *} = v_{\pi_2 *} \ , \ \ q_{\pi_1 *} = q_{\pi_2 *}}$$

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

$v_*(s)$와 $q_*(s,a)$ 의 관계 - **Bellman Optimality Equation**

$$q_*(s,a) = \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] = \sum_{s',r} p(s',r|s,a)[r + \gamma v_*(s')]$$

$$v_*(s) = \max_\pi q_\pi(s,a)$$

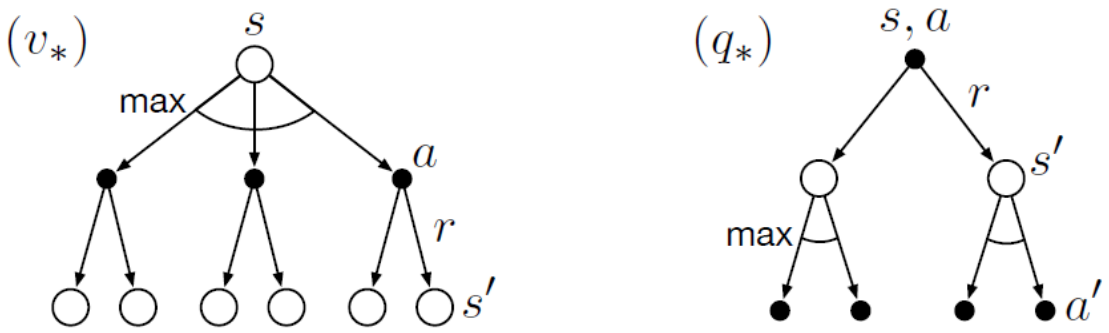

Figure 3.4: Backup diagrams for v_* and q_*

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

$v_*(s)$와 $q_*(s,a)$ 를 재귀적으로 표현하자

$$v_*(s) = \max_\pi q_\pi(s,a) = \max_a \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$$
$$= \max_a \mathbb{E}_\pi[R_t + \gamma G_{t+1} | S_t = s, A_t = a]$$
$$= \max_a \mathbb{E}_\pi[R_t + \gamma v_*(S_{t+1}) | S_t = s, A_t = a]$$

$$= \max_a \sum_{s',r} p(s',r|s,a)[r + \gamma v_*(s')]$$

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

$v_*(s)$와 $q_*(s,a)$ 를 재귀적으로 표현하자

$$q_*(s,a) = \sum_{s',r} p(s',r|s,a)[r + \gamma \max q_*(s',a')]$$

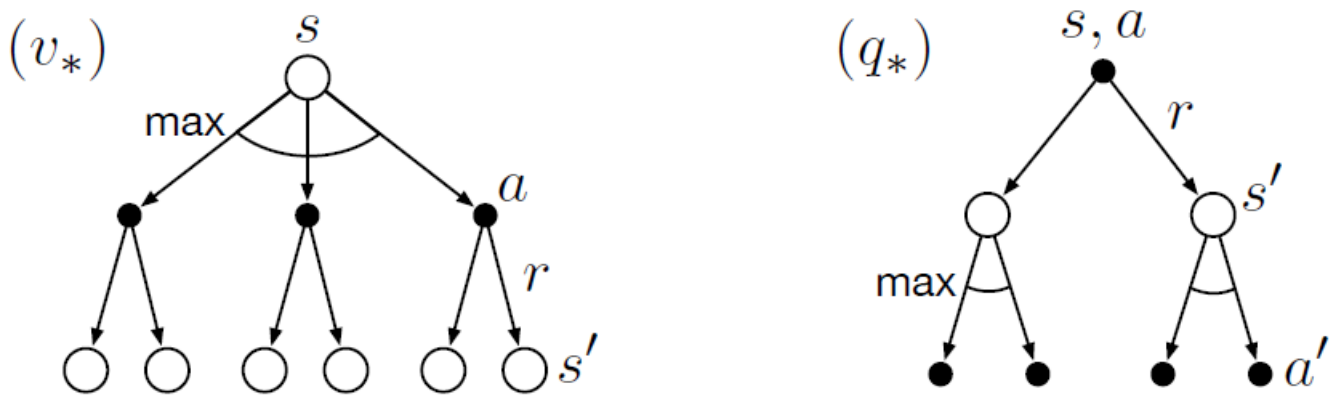

Figure 3.4: Backup diagrams for v_* and q_*

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

$$\boldsymbol{a_* = \arg \pi_*(a_*|s) = \text{argmax}\, q_*(s,a)}$$

$$\boldsymbol{a_* = \arg \pi_*(a_*|s)}$$

$$\boldsymbol{= \text{argmax} \sum_{s',r} p(s',r|s,a)[r + \gamma v_*(s')]}$$

- **Prediction** : v_π **구하기**
- **Control** : v_* **찾기**

How to solve

Optimal Policies and Optimal Value Functions

Optimal Policy

왜 $v_*(s), q_*(s,a)$를 알면 Optimal Policy π_*를 알 수 있나?

- $v_*(s)$ **side**

한단계만 진행해도 최적 action을 찾을 수 있다.

Bellman Optimality Equation에서 최대를 달성하는 Action들을 고르면 그 policy는 optimal이다.

→ v_*에 대해 *Greedy* 한 policy는 Optimal이다.

- $q_*(s,a)$ **side**

$v_*(s)$ 보다 편하다 → 아예 action a가 explicit하게 명시되어 있으니까

$v_*(s)$는 적어도 state transition probability를 알고 있어야 함

근데 $q_*(s,a)$ 는 이런 Dynamics를 몰라도 action 선택이 가능함

와 이제 푸는 방법까지 알았네?

- $v_*(s), q_*(s,a)$ 도 배웠고 여기에 장기적 최적 궤적이 압축되어 있다
- 이걸 그냥 Bellman Optimality Equation에 넣어서 풀면 최적 정책 구해지겠구나?

$$a_* = \arg \pi_*(a_*|s)$$

$$= \operatorname{argmax} \sum_{s',r} p(s',r|s,a)[r + \gamma v_*(s')]$$

와 이제 푸는 방법까지 알았네?

- $v_*(s), q_*(s,a)$ 도 배웠고 여기에 장기적 최적 궤적이 압축되어 있다
- 이걸 그냥 Bellman Optimality Equation에 넣어서 풀면 최적 정책 구해지겠구나?

$$a_* = \arg \pi_*(a_*|s)$$

$$= \operatorname{argmax} \sum_{s',r} p(s',r|s,a)[r + \gamma v_*(s')]$$

No

뭐가 문제인데

- **비용**

계산하는데 너무 시간이 많이 걸려요 + 경우의 수가 많으면 계산량이 비례해서 늘어나요

- **너무 큰 상태/행동 공간**

근사한 가치 함수, 정책, 모델을 다루기 위해 큰 메모리가 필요 (Tabular Method로 감당 X)

그리고 사실 에이전트는 항상 최적 행동을 따를 필요가 없다

→ 에이전트가 마주하는 아주 낮은 확률의 어떤 상황에 대한 보상은 전체 보상에 큰 영향이 없기 때문

그래도 기준은 필요하다

Optimality는 에이전트 행동의 방향성을 제시해준다

그리고 Optimality는 알고리즘을 평가하고 설계하기 위한 이론적 토대를 만들어주는 것에 의미가 있다

- Optimal Policy와 Optimal Value Function들은 이론적으로 중요

The End?

Optimality and Approximation

Chap 4 Dynamic Programming

Chap 5 Monte Carlo Methods

Chap 6 Temporal-Difference Learning

...

II. Approximation Solution Methods

...

Q & A